

Modelos Fundacionales

Curso 2026



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Agenda


1. Introduccción
2. Arquitectura de modelos
3. Impacto, ventajas y desventajas
4. En la práctica...
5. Evaluación, desafíos, tendencias
6. Resumen
7. Práctico y referencias

1. Introducción

1. Introducción – ¿Qué son los modelos fundacionales?

Son una clase de modelos profundos que cumplen con ciertas características clave:

1. **Pre-entrenados:** con datasets masivos de dominios variados y con objetivos agnósticos a la tarea final.
 - Aprendizaje Supervisado o **Auto-Supervisado**.
 - No requieren un gran número de datos etiquetados.
 - Son robustos y con conocimiento transferible a tareas desconocidas.
2. **Adaptables:** son flexibles y pueden volverse eficientes y específicos a un dominio con relativamente pocos datos.
 - **Fine-tuning & Few-shot:** Más contexto sobre el conjunto de datos con el que vamos a trabajar. Puede implicar: modificar una pequeña porción del modelo re-entrenando una o varias capas, agregar nuevas capas o incluir otras series en inferencia como contexto.






1. Introducción – Un poco de historia ...

1 – Precondiciones (pre-2017)

No son papers sobre Modelos Fundacionales (FM) pero colaboraron a que hoy existan:


- **2012 – AlexNet** (Krizhevsky et al., Universidad de Toronto) – [Imágenes, Deep Learning, Redes Neuronales] Una CNN desarrollada para clasificación de imágenes, demostró que las redes profundas entrenadas con grandes volúmenes de datos podían ser muy efectivas. En particular, para el reconocimiento de. El primer indicio de que la escala cambia las cosas de manera cualitativa, hecho posible gracias a el uso de GPUs durante su entrenamiento.
- **2013 – Word2Vec** (Mikolov et al., Google) – [NLP, Unsupervised Learning] La primera demostración contundente de que entrenar previamente representaciones a partir de datos sin procesar y reutilizarlas en etapas posteriores es una estrategia viable.
- **2014-2015 – GloVe, LSTMs for language** (Stanford) – [NLP, Unsupervised Learning] La idea del pre-entrenamiento sigue tomando forma, pero aún se limita a las representaciones, no a modelos completos.



1. Introducción – Un poco de historia ...

2 – La revolución de los Transformers (2017-2019)

- **2017** – "Attention Is All You Need" (Vaswani et al., Google Brain) – [Transformers, Self-attention] La arquitectura base de todo lo que viene a continuación. La auto-atención reemplaza a la recurrencia.
- **2018** – **GPT-1** (Radford et al., OpenAI) – [NLP, Transformers] Forma inicial del paradigma de pre-entrenamiento y fine-tuning decoder-only.
- **2018/2019** – **BERT** (Devlin et al., Google) – [NLP, Transformers, Pre-entrenamiento, Fine-tuning]
 - Pre-BERT: el aprendizaje autosupervisado con modelos de lenguaje como subárea del NLP que avanzaba en paralelo a otros avances.
 - Post-BERT: el paradigma dominante. El pre-entrenamiento bidireccional, el modelado de lenguaje enmascarado, el fine-tuning para cualquier tarea. El plan completo.






*Illustrative example, exact model architecture may vary slightly

1. Introducción – Un poco de historia ...

3 – La escala cambia todo (2020–2021)

- **2020 – GPT-3** (Brown et al., OpenAI, NeurIPS) – [NLP] Primer paper que demuestra el potencial de los FMs. Gracias a un entrenamiento autosupervisado masivo, GPT-3 mostró un gran desempeño en tareas para las que no había sido entrenado explícitamente. Emergen las capacidades few-shot y zero-shot.
- **2021 – DALL-E: Zero-Shot Text-to-Image Generation** (Ramesh et al., OpenAI) – [Vision, Multimodal] Modelos generativos para imágenes.
- **2021 – CLIP** (Radford et al., OpenAI) – [Multimodal] Modelo entrenado con pares de imagen y texto se generaliza a la clasificación de imágenes zero-shot en categorías arbitrarias.
- **2021 – AlphaFold 2** (Jumper et al., DeepMind, Nature) – [Biología] FMs aplicados a la biología para resolver un problema científico de 50 años.
- **2021 – "On the Opportunities and Risks of Foundation Models"** (Bommasani et al., Stanford HAI) – El artículo que dio nombre al paradigma: modelos entrenados en datos variados a gran escala, adaptables a una amplia gama de tareas posteriores.

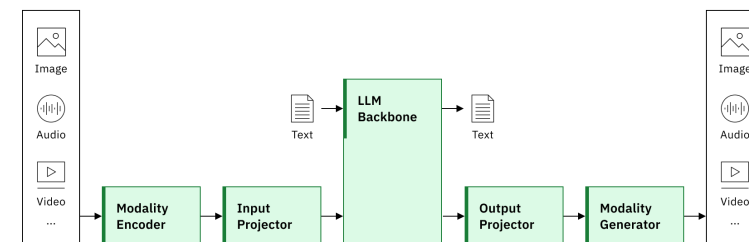



1. Introducción – Un poco de historia ...



4 – Habilidades Emergentes y el Momento Público (2022–2023)


- **2022** – "Emergent Abilities of Large Language Models" (Wei et al., Google) – Los LLM demuestran habilidades emergentes que no están presentes en modelos más pequeños, incluyendo el aprendizaje en contexto, el seguimiento de instrucciones y el razonamiento paso a paso.
- **2022** – **Chinchilla** (Hoffmann et al., DeepMind) – Modelo más pequeño pero mejor entrenado puede superar a los más grandes. No se trata solo del tamaño del modelo, los datos de entrenamiento deben escalar proporcionalmente.
- **2022** – **ChatGPT** (OpenAI) – No es un artículo de investigación, pero posiblemente sea el evento más importante en la historia de los modelos fundacionales: GPT-3.5 optimizado con RLHF (aprendizaje por refuerzo a partir de la retroalimentación humana) hizo que la tecnología fuera accesible para el público general.
- **2023** – **GPT-4, LLaMA, Llama 2** – Se enciende el debate entre modelos abiertos (open-source) y cerrados. Llegan los modelos fundacionales multimodales.



1. Introducción – Un poco de historia ...

5 – Modelos Fundacionales para Series Temporales (2023–presente)

- **2023 – TimeGPT** (Garza & Mergenthaler-Canseco, Nixtla) — Primer FM diseñado específicamente para el pronóstico de series temporales, basado en API y con capacidad zero-shot.
- **2023 – Lag-Llama** (Rasul et al.) — FM decoder-only, probabilístico, de código abierto y univariado.
- **2023 – MOMENT** (Goswami et al., CMU) — FM encoder-only, basado en parches que abarca pronóstico, clasificación, detección de anomalías y más.
- **2024 – TimesFM** (Das et al., Google) — FM decoder-only, basado en parches, abierto y con buen rendimiento zero-shot.
- **2024 – Chronos** (Ansari et al., Amazon) — FM que adapta la arquitectura nativa de un LLM para series temporales mediante la cuantización en tokens.
- **2024 – Moirai** (Woo et al., Salesforce) — FM encoder-only multivariado y probabilístico.
- **2025 – MIRA** (Li et al., Microsoft) — Medical TSFM for Real-World Health Data, de arquitectura decoder-only con Mixture-of-Experts (MoE) y entrenado específicamente para el dominio médico.



2. Arquitectura de modelos fundacionales

2. Arquitectura de modelos fundacionales – Repaso Transformers


Presentada en el artículo «Attention Is All You Need» (Vaswani et al., 2017), los Transformers son una elección popular a la hora de elegir una arquitectura para modelos fundacionales.

A diferencia de las RNN tradicionales o las LSTM, los Transformers:

- Procesan secuencias de entrada completas **en paralelo**, eliminando la necesidad de una recurrencia paso a paso.
- Son más escalables y eficientes para conjuntos de datos grandes.

Su arquitectura presenta:

- Esquema Encoder-Decoder
- Embeddings o proyecciones y Positional Encodings: para asociar una posición (temporal) a la entrada.
- Capas de Auto-Atención normal y enmascarada, y Atención cruzada.
- Red de Feed-Forward




2. Arquitectura de modelos fundacionales – Repaso Transformers

1. Self Attention:


- Permite al modelo evaluar la importancia de los distintos elementos de entrada, incluso cuando se encuentran muy separados entre sí.

2. Ventajas:

- Eficaces para captar dependencias de largo alcance.
 - Aprende representaciones jerárquicas complejas de los datos, gracias a las múltiples capas de autoatención y de propagación.
 - Efectivos para diversas tareas secuenciales.
- Img: <https://poloclub.github.io/transformer-explainer/>



Arquitectura de modelos fundacionales – Ejemplo TimeGPT




Modelo para **forecasting** con arquitectura basada en **Transformers**. Emplea una estructura Encoder-Decoder con conexiones residuales, capas de normalización, CNNs y una salida lineal que proyecta la representación oculta a los valores reales del forecast.

- Se reemplazan las capas de feed-forward de Transformers por **CNNs** para capturar correlaciones locales de los datos.
- Entrenado con 100 mil millones de puntos de datos de series de dominios variados (finanzas, retail, IoT, salud, energía, web traffic, otros).
- Optimizado con Adam y una estrategia de learning rate decreciente hasta el 12% de su valor original.

Arquitectura de modelos fundacionales – Ejemplo TimeGPT

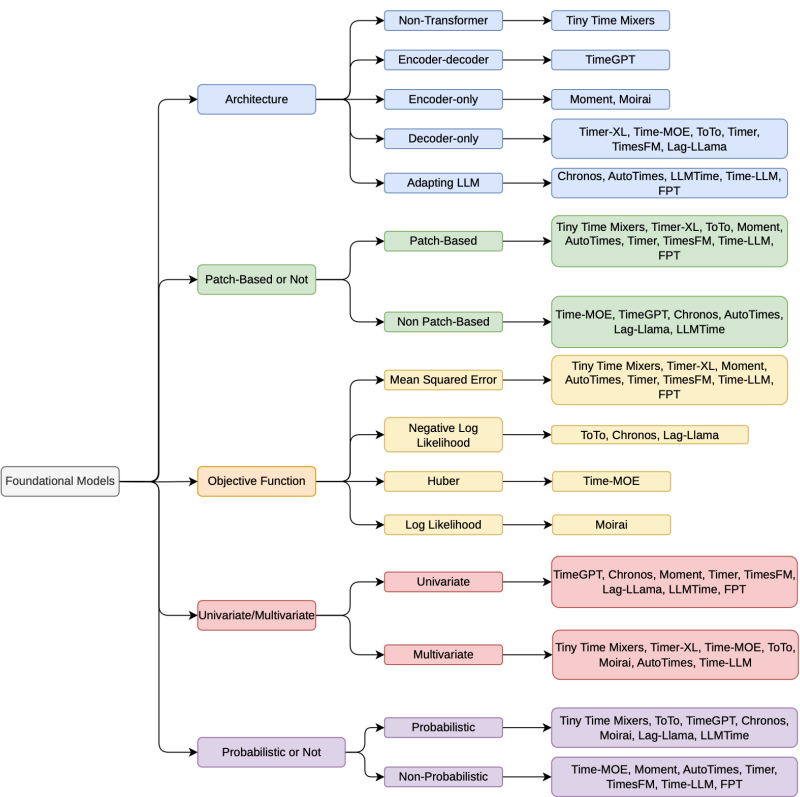
Resultados experimentales

- Se evaluaron 300.000 series de diferentes dominios (los mismos dominios de entrenamiento pero con series no vistas previamente) y lo se comparó el desempeño con otros métodos de forecasting.
- En la figura de la derecha se ve la comparación entre métodos para señales de frecuencia mensual.



2. Arquitectura de modelos – Clasificación de modelos

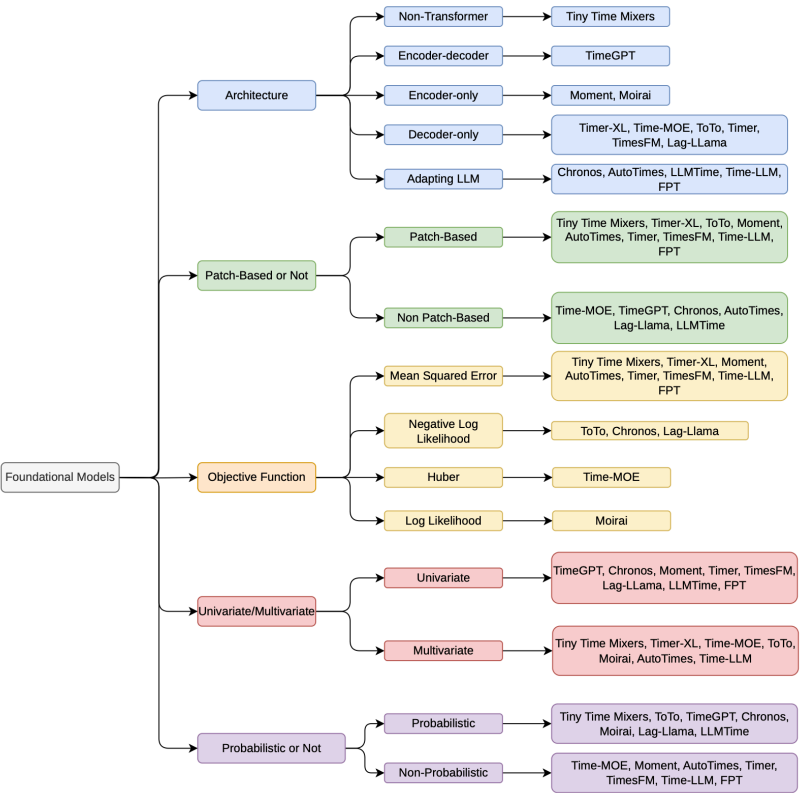

Clasificación de modelos basado en distintas categorías:



2. Arquitectura de modelos – Clasificación de modelos

Clasificación de modelos basado en distintas categorías:

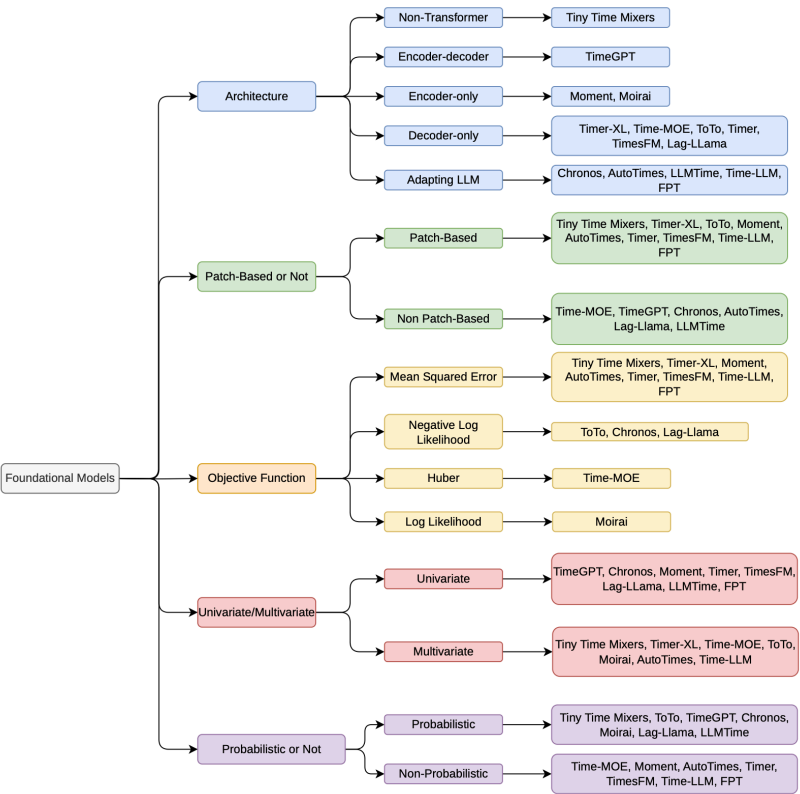

- Arquitectura



2. Arquitectura de modelos – Clasificación de modelos

Clasificación de modelos basado en distintas categorías:

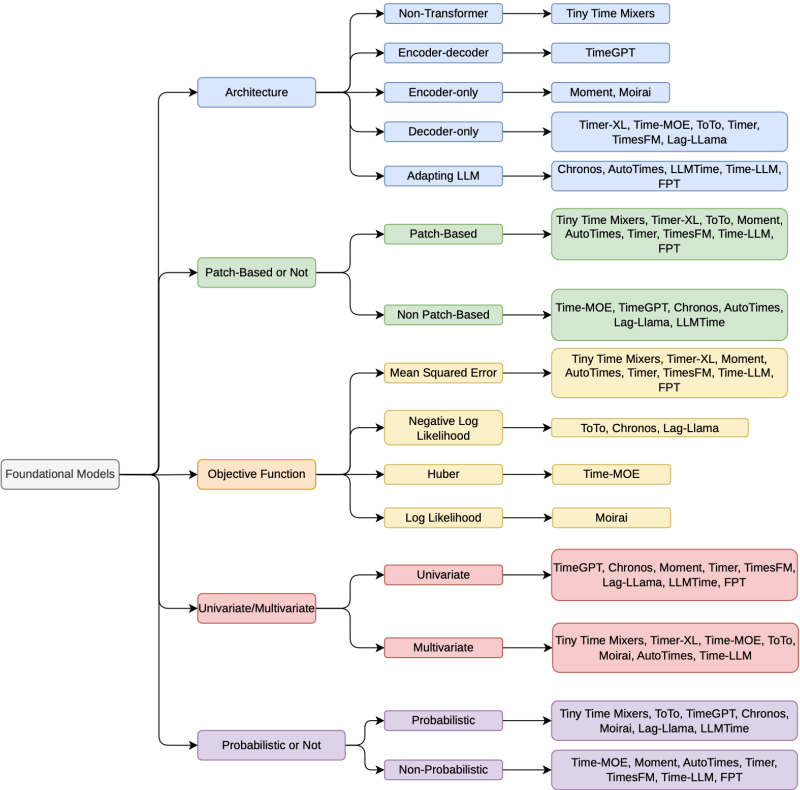

- Arquitectura
- Patch-Based vs. Non-Patch



2. Arquitectura de modelos – Clasificación de modelos

Clasificación de modelos basado en distintas categorías:

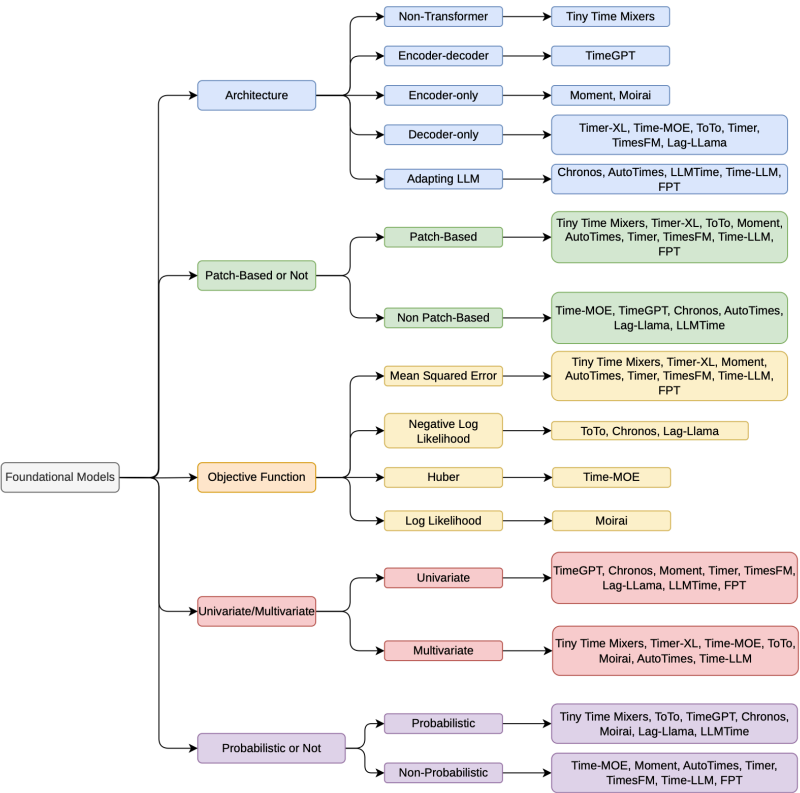

- Arquitectura
- Patch-Based vs. Non-Patch
- Función objetivo



2. Arquitectura de modelos – Clasificación de modelos

Clasificación de modelos basado en distintas categorías:

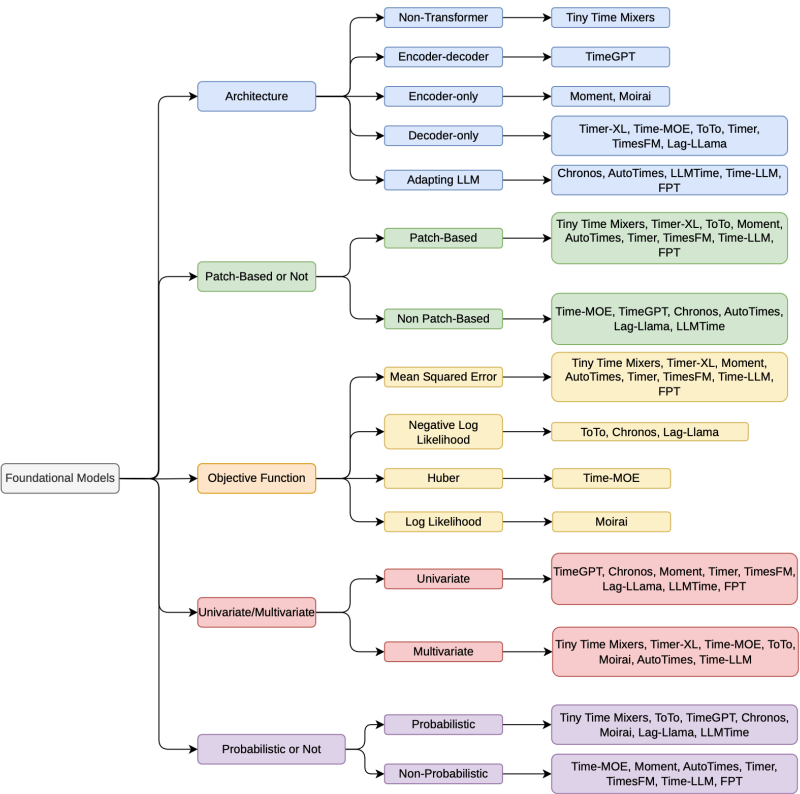

- Arquitectura
- Patch-Based vs. Non-Patch
- Función objetivo
- Univariado vs. Multivariado



2. Arquitectura de modelos – Clasificación de modelos

Clasificación de modelos basado en distintas categorías:

- Arquitectura
- Patch-Based vs. Non-Patch
- Función objetivo
- Univariado vs. Multivariado
- Métodos Probabilísticos vs. No-Probabilísticos



3. Impacto, ventajas y desventajas

3. Impacto

Los modelos fundacionales han transformado muchos dominios, logrando rendimientos del primer nivel en diversas aplicaciones.

En forecasting de series de demanda de enrgía, el artículo "*Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting*" [3] presenta una evaluación de distintos modelos fundacionales (pre-entrenados) contra modelos de arquitectura Transformer entrenados de cero (TFS: "*Trained From Scratch*" Transformers) para datos de demanda de energía en Alemania.

TABLE 6: Model’s MAE_h , MSE_h and $APNE_h$ scores across all datasets

Type	Model	IDEAL			Lower Saxony			REFIT			Southern Germany		
		MAE_h	MSE_h	$APNE_h$	MAE_h	MSE_h	$APNE_h$	MAE_h	MSE_h	$APNE_h$	MAE_h	MSE_h	$APNE_h$
TSFM	Chronos	0.537	1.184	2.194	0.528	1.167	2.211	0.576	1.123	2.105	0.521	0.923	1.778
	Chronos-Bolt	0.513	1.010	2.073	0.490	0.931	2.019	0.528	0.880	1.932	0.478	0.731	1.616
	LagLLama	0.647	1.366	2.269	0.670	1.388	2.275	0.743	1.445	2.229	0.646	1.153	1.876
	Moirai 1.1	-*	-*	-*	1.080	3.305	4.740	1.768	>10	>10	1.149	4.957	6.360
	Sundial	-*	-*	-*	0.499	0.894	1.986	0.529	0.827	1.888	0.497	0.714	1.594
	Time-MoE	-*	-*	-*	0.533	0.892	1.958	0.566	0.845	1.881	0.521	0.710	1.563
	TimesFM	0.514	0.998	2.063	0.491	0.929	2.026	0.530	0.885	1.939	0.478	0.722	1.627
	TimesFM 2.0	0.509	1.035	2.102	0.493	0.974	2.069	0.532	0.919	1.976	0.485	0.758	1.654
TFS	PatchTST	0.516	0.969	2.048	0.494	0.955	2.058	0.535	0.899	1.960	0.499	0.760	1.652
	TFT	0.577	1.126	2.144	0.580	1.147	2.161	0.635	1.171	2.117	0.616	0.973	1.778
	VanillaTransformer	0.549	1.075	2.124	0.556	1.098	2.141	0.603	1.113	2.097	0.573	0.896	1.744
	iTransformer	0.589	1.133	2.143	0.588	1.103	2.123	0.648	1.117	2.068	0.598	0.922	1.737
Baseline	Naive-Forecast	0.703	1.502	2.217	0.608	1.311	2.266	0.733	1.280	2.060	0.718	1.272	1.868
	SeasonalAverage	0.609	1.208	2.128	0.572	1.102	2.071	0.577	0.982	1.965	0.539	0.854	1.696


*Dataset included in TSFM pre-training data.

Observaron que para los 4 conjuntos de datos evaluados, en 3 de ellos los modelos fundacionales logran el mejor y segundo mejor rendimiento.

3. Ventajas y desventajas

1. Ventajas:



- **Zero-shot:** Al ser modelos pre-entrenados, aprovechan su extenso entrenamiento para aprender representaciones generalizadas, lo que les permite funcionar bien sin contar con contexto específico del dominio.
- **Desarrollo:** Eliminan la necesidad de desarrollar, implementar y entrenar modelos específicos para cada caso.
 - A diferencia de modelos anteriores que requerían aprendizaje supervisado específico para cada tarea, ahora se sigue utilizando un **pre-entrenamiento semi-supervisado**, que luego pueden adaptarse a tareas específicas mediante un ajuste fino (**fine-tuning**).
- El mismo modelo puede ser utilizado para diversas tareas: forecasting, detección de anomalías, generación sintética.
- Buen rendimiento en escenarios de datos limitados.




3. Ventajas y desventajas

2. Desventajas:


- Difíciles de interpretar.
- Sesgos de representación por dominio (¿qué industrias están sobre-representadas en los datos de entrenamiento?).
- Algunos son de código cerrado, solo accesibles en esquemas pagos tipo API (posible "fuga de datos" sensibles).




United States



Australia



Ethiopia



Pakistan



*Shankar, Shreya et al. "No Classification without Representation:

Assessing Geodiversity Issues in Open Data Sets for the Developing World." arXiv: Machine Learning (2017)

4. En la práctica...

4. En la práctica... – ¿Qué cambia al usar FMs?

- No entrenamos modelos de cero:
 - Elegimos un modelo pre-entrenado y lo utilizamos como nos resulte más conveniente: zero-shot, few-shot, fine-tuning.
 - En lugar de construir un modelo de cero adapto un modelo existente a mis necesidades.
- En un contexto con pocos datos, puedo conseguir resultados razonables.


4. En la práctica... – Discusión

¿En qué contexto elijo qué modelo?

Categoría	Clásicos	Deep Learning	Modelos Fundacionales
Cantidad de datos	Baja	Alta	Baja
Explicabilidad	Alta	Media	Baja
Velocidad	Alta	Baja	Alta
Rendimiento	...	...	...

4. En la práctica... – Datos de demanda energética

Predicción de una semana para los datos de demanda de la estación MER. Para los primeros dos métodos se utilizaron **9 años** de datos de entrenamiento, mientras que para el modelo fundacional solamente se le mostraron los **28 días** previos.



Modelo	MAE	MAPE	MSE	Tiempo
XGBoost	0.23	0.07	0.10	17 s
TCN	0.37	0.12	0.21	6 min
Chronos	0.16	0.05	0.05	1 s

5. Evaluación, desafíos, tendencias

5. Evaluación, desafíos, tendencias

- **Métricas específicas de la tarea:**
 - Usamos las mismas métricas de siempre, dependiendo de la tarea.
- **Interpretabilidad / Explicabilidad:**
 - ¿Qué aprendió el modelo realmente?
 - En dominios donde es necesario poder explicar el porqué detrás de su accionar, se vuelven inapropiados.
 - Mapas de atención como en texto se vuelven menos interpretables en series temporales.
- **Construcción de datasets del mundo real:**
 - A diferencia de los grandes cuerpos de texto, la construcción de un dataset de series temporales multivariadas sigue siendo un desafío, tanto en escala como en calidad.
 - Equilibrio de las proporciones de muestras entre dominios heterogéneos, para no sesgar el pre-entrenamiento, lo cual dificulta la generalización.
- **Tendencias futuras:**
 - Modelos más pequeños y eficientes, multimodalidad texto+series y agentes que usan FMs de forecasting como herramienta.

6. Resumen

6. Resumen

- Los FMs son modelos profundos **pre-entrenados** con datos masivos y variados, que pueden adaptarse a tareas específicas con pocos datos.
- **Ventajas:** un solo modelo sirve para **varias tareas** (forecasting, anomalías, generación sintética), **menor costo computacional** (no hay que entrenar desde cero), buen desempeño con **datos limitados**.
- **Desventajas:** baja **interpretabilidad**, posible **código cerrado**/dependencia de APIs (riesgo de fuga de datos), eventualmente alto costo de inferencia.
- **Desafíos abiertos:** mejorar su interpretabilidad y construir datasets de series temporales multivariadas de calidad y a gran escala.

7. Práctico y referencias

Ejemplos prácticos

- [Práctico 6 - Modelos Fundacionales \(EVA\)](#)
- [Ejemplo Python TimesFM - Forecasting con covariables](#)
- [Ejemplo Chronos - Forecasting con covariables](#)

Referencias

- Hyndman, R.J., Athanasopoulos, G., Garza, A., Challu, C., Mergenthaler, M., & Olivares, K.G. (2026). Forecasting: Principles and Practice, the Pythonic Way. OTexts: Melbourne, Australia. Available at: [OTexts.com/fpppy](https://otexts.com/fpppy). [Chapter 15: Foundation forecasting models](#).
- Liang, Y., Wen, H., Nie, Y., Jiang, Y., Jin, M., Song, D., ... & Wen, Q. (2024, August). Foundation models for time series analysis: A tutorial and survey. In *Proceedings of the 30th ACM SIGKDD conference on knowledge discovery and data mining* (pp. 6555-6565).