

Repaso de Aprendizaje Automático




FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Aprendizaje automático



Tipos de aprendizaje



FACULTAD DE
INGENIERÍA




UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Tipos de aprendizaje


Aprendizaje supervisado

- Tenemos pares de datos de entrada-salida generados por humanos
- Según el tipo de salida dos posibles problemas:
 - salida categórica: clasificación
 - salida numérica: regresión

Problema de Clasificación



Problema de Regresión





Tipos de aprendizaje

Aprendizaje no supervisado

La mayor parte de los datos disponibles no están etiquetados. Su potencial etiquetado requiere intervención humana (muchas veces expertos especializados) y su costo es muy alto.

- **Clustering:** descubrir estructura dentro de un conjunto de datos, agrupándolos en subconjuntos (clusters) que muestren una cierta coherencia o similitud interna.



Aprendizaje y generalización




FACULTAD DE
INGENIERÍA




UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

El problema de aprendizaje



El problema de aprendizaje

- El set de hipótesis elegido influye en:
 - El error dentro de la muestra E_{in} (aproximación a las muestras disponibles)
 - El error fuera de la muestra E_{out} (error fuera de muestra)
- Queremos que nuestro modelo
 - aproxime bien a las muestras (x,y) disponibles
 - generalice bien para nuevos datos
- Va a existir un compromiso



Ajuste óptimo y Sobreajuste




FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Ajuste óptimo

- Complejidad óptima
- Captura **toda** la estructura
- No captura **particularidades**
- **Cómo** identificar modelo ideal?
 - Selección de modelos
 - Validación cruzada
- Depende de cantidad de datos de entrenamiento disponibles!
- Depende del problema




Sobreajuste (overfitting)

Escenario

- $g(\mathbf{x})$ demasiado compleja
- Demasiados parámetros
- Pocas muestras

Consecuencia

- Captura particularidades
- No captura generalidades



El modelo funciona bien en los datos de entrenamiento, pero no generaliza bien.

Siempre se puede construir un modelo que funcione perfecto con los datos de entrenamiento.

Métodos de aprendizaje supervisado



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Aprendizaje supervisado

- Clasificación

- K-NN
- Árboles de decisión
- Modelos lineales
 - Perceptrón
 - Regresión logística
 - SVM
- Extensión a modelos no-lineales
 - Kernel SVM
 - Modelo lineal en un espacio de características de mayor dimensión
 - Kernel trick

- Regresión

- Regresión lineal
- Regresión polinómica
- Árboles de decisión
- SVM y Kernel SVM
- Regresión lineal con regularización
 - Lasso, Ridge, ElasticNet

Ensamble de predictores

- Entrenamiento en paralelo, sobre un mismo conjunto de entrenamiento
 - Mezcla de expertos:
distintos tipos de predictor (SVM, k-NN, etc.) entrenados sobre los mismos datos
- Entrenamiento en paralelo, con distintos conjuntos de entrenamiento
 - Bagging (Bootstrap Aggregating):
distintos modelos del mismo tipo entrenados sobre distintos muestreos de los datos
 - Random forest:
combina bagging sobre árboles de decisión con selección aleatoria de atributos
- Entrenamiento secuencial o en cascada
 - Boosting: al pasar por la cascada de predictores, a las muestras difíciles de clasificar se les va aumentando el peso en el costo total, para que los predictores cuesta arriba se focalicen en su predicción. La decisión es un voto ponderado por el desempeño de cada predictor.

Training dataset

Obs	X_1	X_2	X_3	X_4	X_5	Y
1	X_{11}	X_{21}	X_{31}	X_{41}	X_{51}	0
2	X_{12}	X_{22}	X_{32}	X_{42}	X_{52}	1
3	X_{13}	X_{23}	X_{33}	X_{43}	X_{53}	0
4	X_{14}	X_{24}	X_{34}	X_{44}	X_{54}	0
5	X_{15}	X_{25}	X_{35}	X_{45}	X_{55}	1

Bootstrap



Obs	X_1	X_3	X_4	Y
1	X_{11}	X_{31}	X_{41}	0
2	X_{12}	X_{32}	X_{42}	1
5	X_{15}	X_{35}	X_{45}	1
1	X_{11}	X_{31}	X_{41}	0
5	X_{15}	X_{35}	X_{45}	1

Obs	X_2	X_3	X_4	Y
1	X_{21}	X_{31}	X_{41}	0
3	X_{23}	X_{33}	X_{43}	0
4	X_{24}	X_{34}	X_{44}	0
3	X_{23}	X_{33}	X_{43}	0
2	X_{22}	X_{32}	X_{42}	0


... ..

Obs	X_1	X_2	X_5	Y
2	X_{12}	X_{22}	X_{52}	1
3	X_{13}	X_{23}	X_{53}	0
5	X_{15}	X_{25}	X_{55}	1
5	X_{15}	X_{25}	X_{55}	1
3	X_{13}	X_{23}	X_{53}	0

Ensemble of trees



... ..



Aggregation

Majority decision

Métodos de aprendizaje no supervisado



FACULTAD DE
INGENIERÍA





UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Aprendizaje no supervisado

- Reducción de dimensiones

- Maldición de la dimensionalidad / Bendición de la no uniformidad
- Objetivos:
 - Visualización
 - Extraer características relevantes.
 - Reducir costo computacional
- Proyección
 - PCA
 - Kernel PCA
- Aprendizaje de variedades
 - Locally linear embedding





- Clustering

- K-Means
- DBSCAN

- Estimación de densidades

- Mezcla de gaussianas

- Detección de anomalías



Parámetros e hiperparámetros



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Parámetros e hiperparámetros

- Parámetros
 - Se determinan durante el entrenamiento
 - Ejemplo:
 - Los pesos que determinan el hiperplano en SVM
- Hiper-parámetros
 - Se eligen
 - No cambian en el entrenamiento
 - Ejemplo:
 - valor de C en SVM
 - tipo de kernel y valor de gamma en Kernel SVM

Entrenamiento de modelos




FACULTAD DE
INGENIERÍA





UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Parámetros se determinan en el entrenamiento



Gradient descent (GD)

- Algoritmo genérico de optimización
- Idea
 - Llegar al óptimo en forma iterativa
 - En cada paso:
 - Buscar la dirección de mayor crecimiento del costo y moverse en el sentido opuesto




Gradient descent (GD)



- Llegar al óptimo en forma iterativa
- En cada paso:
 - Buscar la dirección de mayor crecimiento del costo y moverse en el sentido opuesto

$$\nabla C(\theta) = \begin{bmatrix} \frac{\partial C}{\partial \theta_0} \\ \frac{\partial C}{\partial \theta_1} \\ \vdots \\ \frac{\partial C}{\partial \theta_n} \end{bmatrix}$$


$$\theta^{k+1} = \theta^k - \eta \nabla_{\theta} C(\theta)$$



Gradient descent (GD)



Batch GD, Stochastic GD y Batch GD



Búsqueda de hiperparámetros y evaluación de modelos



FACULTAD DE
INGENIERÍA





UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Búsqueda de mejores hiperparámetros y evaluación de modelos

- Dos tareas:
 - Elegir los mejores hiperparámetros
 - Evaluar el modelo
- No se debe realizar sobre los mismos datos
 - Riesgo de sobre-ajuste
- Partir los datos
 - Entrenamiento / Validación / Test
 - Validación cruzada

Búsqueda de mejores hiperparámetros y evaluación de modelos



Búsqueda de mejores hiperparámetros con validación cruzada

- Una búsqueda consta de:
 - Un estimador
 - Un espacio de parámetros donde buscar
 - Un método de búsqueda
 - Un esquema de validación cruzada
 - Una función de score
- **GrisSearchCV**
 - Búsqueda exhaustiva sobre una grilla de parámetros
- **RandomizedSearchCV**
 - Búsqueda en forma de muestreo aleatorio sobre el espacio de parámetros

Métricas de desempeño




FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Performance measurements



-  TP: true positives
success
 -  TN: true negatives
correct rejection
 -  FP: false positives
type I error (false alarm)
 -  FN: false negatives
type II error
-  system login
 disease detection

Total samples: $N = TP + FP + TN + FN$

Accuracy: $ACC = \frac{(TP + TN)}{N}$

Sensitivity/Recall: $TPR = \frac{TP}{(TP + FN)}$

Specificity: $TNR = \frac{TN}{(TN + FP)}$

Precision: $PPV = \frac{TP}{(TP + FP)}$

False positive rate: $FPR = \frac{FP}{(FP + TN)}$

False discovery rate: $FDR = \frac{FP}{(FP + TP)}$

F-score: $F = \frac{2TP}{(2TP + FP + FN)}$

¿cuánto se acerca a los valores reales? exactitud

tasa de enfermos correctamente detectados

tasa de sanos correctamente clasificados

de los clasificados positivos ¿cuántos son los realmente positivos?


probabilidad de una falsa alarma.

Media armónica entre TPR y PPV.


Confusion matrix

		Positive (sick)	Negative (healthy)	
Real labels	Positive (sick)	TP	FN	Positive (sick)
	Negative (healthy)	FP	TN	Negative (healthy)
		Predicted labels		


Score de confianza. Distancia al hiperplano




Compromiso precision/recall



Compromiso precision/recall




Curva precision vs recall



Curva precision vs recall. Comparación de algoritmos

PR-AUC

Area under curve





FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY