

Series Temporales

Patrones en series temporales. Descomposiciones



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Fuentes

El material de estas diapos está basado en:

- Forecasting: Principles and Practice, the Pythonic Way. Rob J Hyndman et al. [1]
<https://otexts.com/fpppy/>
- Curso “Time series analysis with Python” de Filippo Maria Bianchi
<https://github.com/FilippoMB/python-time-series-handbook>

[1] Hyndman, R.J., Athanasopoulos, G., Garza, A., Challu, C., Mergenthaler, M., & Olivares, K.G. (2026). Forecasting: Principles and Practice, the Pythonic Way. OTexts: Melbourne, Australia. Available at: <https://otexts.com/fpppy/>. Accessed: 29 June 2026.

Componentes



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Componentes de una serie



- **Tendencia**
 - Existe una tendencia cuando hay un aumento o disminución a largo plazo en los datos.
 - No tiene por qué ser lineal
- **Estacionalidad**
 - Un patrón estacional se produce cuando una serie temporal se ve afectada por factores estacionales, como la época del año o el día de la semana.
 - La estacionalidad es siempre de un periodo fijo y conocido
- **Ciclos**
 - Un ciclo se produce cuando los datos muestran subidas y bajadas que no tienen una frecuencia fija.
 - Un ejemplo son las fluctuaciones de las condiciones económicas.

Descomposición

- Una serie temporal se puede pensar formada por 3 componentes
 - Un componente de tendencia (y eventual ciclo)
 - Un componente estacional
 - Un componente restante (contiene cualquier otro elemento de la serie temporal)
- La descomposición de la serie puede tener distintos objetivos
 - entender mejor la serie
 - ayudar a mejorar las predicciones

Descomposición

- **Aditiva**
 - Adecuada si la magnitud de las fluctuaciones estacionales, o la variación en torno a la tendencia-ciclo, no varía con el nivel de la serie temporal
- **Multiplicativa**
 - Apropiaada cuando la variación del patrón estacional, o la variación en torno a la tendencia-ciclo, parece ser proporcional al nivel de la serie temporal



Descomposición

- Aditiva $y_t = S_t + T_t + R_t$
- Multiplicativa $y_t = S_t \times T_t \times R_t$

S_t es el componente estacional




T_t es el componente de tendencia-ciclo

R_t es el componente remanente

Descomposición

- Una alternativa a la descomposición multiplicativa es transformar previamente los datos mediante un logaritmo

$$y_t = S_t \times T_t \times R_t \quad \text{es equivalente a} \quad \log y_t = \log S_t + \log T_t + \log R_t.$$



Ajustes y transformaciones

- Otros ajustes y transformaciones pueden ser útiles antes de una descomposición
- Objetivos de los ajustes y transformaciones:
 - simplificar los patrones y hacerlos más coherentes en toda la serie
 - eliminar fuentes de variación conocidas
- Ejemplos de ajustes
 - Ajustes de calendario.
 - Datos acumulados mensuales pueden estar influidos porque hay meses de distinto largo. Pasar a valores por día
 - Ajustes de población
 - Datos sensibles al número de personas. Pasar a datos per-capita
 - Ajustes por inflación
 - Ajustar datos por IPC

Ajuste y transformaciones

- Transformaciones matemáticas

- Log $w_t = \log(y_t)$

- Potencia $w_t = y_t^p$

- transformaciones de Box-Cox

$$w_t = \begin{cases} \log(y_t) & \text{if } \lambda = 0; \\ (\text{sign}(y_t)|y_t|^\lambda - 1)/\lambda & \text{otherwise.} \end{cases}$$

Descomposición clásica



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY


Medias móviles

- El suavizado de media móvil es un paso inicial de los métodos clásicos de descomposición
- Permite estimar la componente T
- Ejemplo: Suavizado con una ventana móvil de largo 3 centrada



Medias móviles

Total Australian exports



Medias móviles de medias móviles

- Cuando el largo de ventana es impar la ventana es simétrica
 - Largo $m = 2k + 1$, Se promedia el valor central y k muestras a cada lado
- Cuando el largo de ventana es par no queda simétrica
- Se puede en el caso par tomar una media móvil de largo 2 de la media móvil previa
 - Ejemplo: media móvil de 4 seguida de media móvil de 2
Notación: 2 x 4 - MA (2 moving average of a 4 moving average)

$$\begin{aligned}\hat{T}_t &= \frac{1}{2} \left[\frac{1}{4} (y_{t-2} + y_{t-1} + y_t + y_{t+1}) + \frac{1}{4} (y_{t-1} + y_t + y_{t+1} + y_{t+2}) \right] \\ &= \frac{1}{8} y_{t-2} + \frac{1}{4} y_{t-1} + \frac{1}{4} y_t + \frac{1}{4} y_{t+1} + \frac{1}{8} y_{t+2}.\end{aligned}$$

Estimación de la tendencia-ciclo

- Si por ejemplo nuestros datos son trimestrales con estacionalidad anual
 - Período 4
 - Si aplicamos 2 x 4 - MA

$$\hat{T}_t = \frac{1}{8}y_{t-2} + \frac{1}{4}y_{t-1} + \frac{1}{4}y_t + \frac{1}{4}y_{t+1} + \frac{1}{8}y_{t+2}$$

- Cada trimestre móvil recibe la misma ponderación
 - la variación estacional se promedia
 - Los valores resultantes en $\hat{T}_t$ tendrán poca o ninguna variación estacional restante

Estimación de la tendencia-ciclo

- En general
 - una media móvil de $2 \times m$ equivale a una media móvil ponderada de orden $m+1$ en la que todas las observaciones tienen una ponderación de $1/m$, excepto el primer y el último término, que tienen una ponderación de $1/(2m)$
 - si el período estacional es par y de orden m , utilizamos una media móvil ponderada $2 \times m$ para estimar el ciclo tendencial

Estimación de la tendencia-ciclo

- Ejemplo de datos de empleo en retail
 - Datos mensuales
 - Estacionalidad anual
 - $m=12$



Descomposición aditiva

- Paso 1

- Si m es un número par, calcule el componente de tendencia-ciclo $\hat{T}_t$ utilizando un $2 \times m$ -MA.
Si m es un número impar, calcule el componente de tendencia-ciclo $\hat{T}_t$ usando un m -MA.

- Paso 2

- Calcular la serie sin tendencia $y_t - \hat{T}_t$

- Paso 3

- Calcular un período de la componente estacional. Por ejemplo si los datos son mensuales y el período anual, promediar todos los eneros, todos los febreros, etc. de la serie sin tendencia. Sacarle la media al período calculado. Repetir el período calculado para todos los años de la serie y con eso formar $\hat{S}_t$.


- Paso 4

- Calcular $\hat{R}_t = y_t - \hat{T}_t - \hat{S}_t$.

Descomposición aditiva

Classical additive decomposition of total US retail employment

Employed = trend + seasonal + random



Descomposición multiplicativa

- Paso 1

- Si m es un número par, calcule el componente de tendencia-ciclo $\hat{T}_t$ utilizando un $2 \times m$ -MA.
Si m es un número impar, calcule el componente de tendencia-ciclo $\hat{T}_t$ usando un m -MA.

- Paso 2

- Calcular la serie sin tendencia $y_t / \hat{T}_t$.

- Paso 3

- Calcular un período de la componente estacional. Por ejemplo si los datos son mensuales y el período anual, promediar todos los eneros, todos los febreros, etc. de la serie sin tendencia. Sacarle la media al período calculado. Repetir el período calculado para todos los años de la serie y con eso formar $\hat{S}_t$.

- Paso 4

- Calcular $\hat{R}_t = y_t / (\hat{T}_t \hat{S}_t)$

Descomposición STL



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Descomposición STL

- STL = Seasonal and Trend decomposition using Loess
- Desarrollado en 1990
- Loess es un método de regresión local que permite ajustar curvas de tendencia y estacionalidad por tramos
- Fortalezas
 - admite deriva temporal del componente estacional
 - permite control del usuario de la suavidad de la componente de tendencia-ciclo
 - robusto ante outliers. No afectan estacionalidad y tendencia, quedan como parte del residuo
- Debilidades
 - sólo descomposiciones aditivas. Descomposiciones multiplicativas puede hacerse aplicando previamente una transformación, hacer la descomposición y luego la transformación inversa

LOESS (Local Regression Smoothing)

- Para cada punto t de la serie temporal, se selecciona una ventana de vecinos más cercanos.
- Se asignan ponderaciones a los vecinos en función de su proximidad a t , utilizando una función de ponderación, como el núcleo gaussiano.
- Se realiza una regresión ponderada utilizando los vecinos y sus ponderaciones asignadas.
- El valor ajustado para el punto t se obtiene mediante regresión local.
- El proceso se repite para todos los puntos de la serie temporal, obteniendo así una estimación suavizada de la tendencia.

Descomposición MSTL



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Descomposición MSTL

- MSTL = Multiple Seasonal-Trend decomposition using LOESS
- Extensión de STL que puede manejar múltiples patrones estacionales
 - Por ejemplo, estacionalidad diaria, semanal y anual simultánea

Implementaciones - Bibliotecas



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

statsmodels.tsa.seasonal.seasonal_decompose

- Seasonal decomposition using moving averages
- https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.seasonal_decompose.html

- ```
statsmodels.tsa.seasonal.seasonal_decompose(
 x,
 model='additive',
 filt=None,
 period=None,
 two_sided=True,
 extrapolate_trend=0
)
```

## statsmodels.tsa.seasonal.STL

- Season-Trend decomposition using LOESS
- <https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.STL.html>
- 

```
STL(endog, period=None, seasonal=7, trend=None, low_pass=None,
 seasonal_deg=1, trend_deg=1, low_pass_deg=1, robust=False, seasonal_jump=1,
 trend_jump=1, low_pass_jump=1)
```

# Nixtla MSTL

- <https://nixtlaverse.nixtla.io/statsforecast/docs/models/multipleseasonaltrend.html>
- Tutorial de uso:  
<https://nixtlaverse.nixtla.io/statsforecast/docs/tutorials/multipleseasonalities.html#multiple-seasonalities>



FACULTAD DE  
INGENIERÍA



UNIVERSIDAD  
DE LA REPÚBLICA  
URUGUAY