

Series Temporales

Exponential smoothing



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Fuentes

El material de estas diapos está basado en:

- Forecasting: Principles and Practice, the Pythonic Way. Rob J Hyndman et al. [1]
<https://otexts.com/fpppy/>
- Statistical Forecast: Lightning fast forecasting with statistical and econometric models [2]
<https://github.com/Nixtla/statsforecast>

[1] Hyndman, R.J., Athanasopoulos, G., Garza, A., Challu, C., Mergenthaler, M., & Olivares, K.G. (2026). Forecasting: Principles and Practice, the Pythonic Way. OTexts: Melbourne, Australia. Available at: <https://otexts.com/fpppy/>. Accessed: 29 June 2026.

[2] Garza, Azul, Max Mergenthaler Canseco, Cristian Challú, and Kin G. Olivares. "StatsForecast: Lightning fast forecasting with statistical and econometric models." *PyCon Salt Lake City, Utah, US 2022* (2022): 6.

Simple Exponential Smoothing



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Intuición

- Dos casos extremos

- Método naive
- Promedio histórico

$$\hat{y}_{T+h|T} = y_T$$

$$\hat{y}_{T+h|T} = \frac{1}{T} \sum_{t=1}^T y_t$$

- Hacer algo intermedio

- Pesar diferente las muestras anteriores
- Dar más importancia a las muestras recientes
- Decaimiento exponencial hacia el pasado

$$\hat{y}_{T+1|T} = \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots$$

Características

- Método de los años 50 (Brown, 1959; Holt, 1957; Winters, 1960)
- Para predecir valores futuros en base a observaciones históricas
- Para series univariadas
- Se predice el próximo valor como una suma ponderada de valores anteriores
 - Los pesos decaen exponencialmente hacia el pasado
 - Parámetro principal: "smoothing factor" α (alfa) entre 0 y 1

Ecuación de predicción

$$\hat{y}_{T+1|T} = \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots,$$

y_T Valor observado en el instante T

$\hat{y}_{T+1|T}$ Predicción para el siguiente período (T+1)

Reformulación

- Vamos a reformular el suavizado de dos maneras distintas:
 - Expresado como promedio ponderado
 - Expresado en componentes

Expresado como promedio ponderado

- En cambio, podemos poner la predicción en T+1 como el promedio ponderado entre la muestra en T y la predicción anterior:

$$\hat{y}_{T+1|T} = \alpha y_T + (1 - \alpha) \hat{y}_{T|T-1}$$

- Similar para todos los instantes de tiempo

$$\hat{y}_{t+1|t} = \alpha y_t + (1 - \alpha) \hat{y}_{t|t-1} \quad \text{para } t = 1, \dots, T$$

- Suponiendo conocida la predicción inicial como un valor ℓ_0

$$\hat{y}_{2|1} = \alpha y_1 + (1 - \alpha)\ell_0$$

$$\hat{y}_{3|2} = \alpha y_2 + (1 - \alpha)\hat{y}_{2|1}$$

$$\hat{y}_{4|3} = \alpha y_3 + (1 - \alpha)\hat{y}_{3|2}$$

$$\vdots$$

$$\hat{y}_{T|T-1} = \alpha y_{T-1} + (1 - \alpha)\hat{y}_{T-1|T-2}$$

$$\hat{y}_{T+1|T} = \alpha y_T + (1 - \alpha)\hat{y}_{T|T-1}.$$

- Sustituyendo cada ecuación en la siguiente

$$\hat{y}_{3|2} = \alpha y_2 + (1 - \alpha) [\alpha y_1 + (1 - \alpha) \ell_0]$$

$$= \alpha y_2 + \alpha(1 - \alpha)y_1 + (1 - \alpha)^2 \ell_0$$

$$\hat{y}_{4|3} = \alpha y_3 + (1 - \alpha) [\alpha y_2 + \alpha(1 - \alpha)y_1 + (1 - \alpha)^2 \ell_0]$$

$$= \alpha y_3 + \alpha(1 - \alpha)y_2 + \alpha(1 - \alpha)^2 y_1 + (1 - \alpha)^3 \ell_0$$

$\vdots$

$$\hat{y}_{T+1|T} = \sum_{j=0}^{T-1} \alpha(1 - \alpha)^j y_{T-j} + (1 - \alpha)^T \ell_0.$$

Este último término se hace muy pequeño con T grande y llegamos a la misma ecuación de predicción anterior

Expresado en base a componentes

- Podemos expresarlo como dos ecuaciones
 - Una ecuación de predicción
 - Una ecuación que actualiza el componente
 - en este caso el estado está determinado por un único componente, el nivel ℓ_t

Forecast equation $\hat{y}_{t+h|t} = \ell_t$

Smoothing equation $\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$

Si sustituimos ℓ_t por $\hat{y}_{t+1|t}$ y ℓ_{t-1} por $\hat{y}_{t|t-1}$ en la ecuación de suavizado, recuperaremos la forma media ponderada de suavizado exponencial simple.

- Esta forma de expresar el modelo parece innecesaria en este caso pero adquiere sentido cuando se hace más complejo el modelo

Optimización

- Para calcular predicciones es necesario seleccionar valores de α y ℓ_0 .
- Estos valores se obtienen minimizando el costo dado por

$$\text{SSE} = \sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 = \sum_{t=1}^T e_t^2$$

Agregado de una tendencia



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Simple exponential smoothing (SES)

Forecast equation

$$\hat{y}_{t+h|t} = \ell_t$$

Smoothing equation

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$$

Double exponential smoothing - Holt

- SES no funciona si hay una tendencia
- Propuesto por Holt en 1957
- Idea: Agregar una ecuación de tendencia a la formulación

Forecast equation

$$\hat{y}_{t+h|t} = \ell_t + hb_t$$

Level equation

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

Trend equation

$$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$$

- Limitaciones
 - Se supone que la serie es estacionaria
 - Sirve si la tendencia es lineal

Double exponential smoothing

Holt (1957) amplió el método de Holt para permitir la predicción de datos con tendencia. Este método implica una ecuación de predicción y dos ecuaciones de suavizado (una para el nivel y otra para la tendencia):

Forecast equation	$\hat{y}_{t+h t} = \ell_t + hb_t$
Level equation	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
Trend equation	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1},$

donde ℓ_t denota una estimación del nivel de la serie en el tiempo t , b_t denota una estimación de la tendencia (pendiente) de la serie en el tiempo t , α es el parámetro de suavizado para el nivel, $0 \leq \alpha \leq 1$, y β^* es el parámetro de suavizado para la tendencia, $0 \leq \beta^* \leq 1$. (Denotamos esto como β^* en lugar de β por razones que se explicarán en la sección 8.5).

Al igual que con el alisado exponencial simple, la ecuación de nivel aquí muestra que ℓ_t es un promedio ponderado de la observación y_t y el pronóstico de entrenamiento de un paso adelante para el tiempo t , aquí dado por $\ell_{t-1} + b_{t-1}$. La ecuación de tendencia muestra que b_t es una media ponderada de la tendencia estimada en el tiempo t basada en $\ell_t - \ell_{t-1}$ y b_{t-1} , la estimación anterior de la tendencia.

Double exponential smoothing amortiguado (damped)

Junto con los parámetros de suavizado α y β^* (con valores entre 0 y 1 como en el método de Holt), este método también incluye un parámetro de amortiguación $0 < \phi < 1$:

$$\begin{aligned}\hat{y}_{t+h|t} &= \ell_t + (\phi + \phi^2 + \dots + \phi^h)b_t \\ \ell_t &= \alpha y_t + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1}) \\ b_t &= \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}.\end{aligned}$$

Si $\phi = 1$, el método es idéntico al método lineal de Holt. Para valores entre 0 y 1, ϕ amortigua la tendencia para que se aproxime a una constante en algún momento en el futuro. De hecho, las previsiones convergen a $\ell_T + \phi b_T / (1 - \phi)$ como $h \rightarrow \infty$ para cualquier valor $0 < \phi < 1$. Esto significa que las previsiones a corto plazo son tendenciales, mientras que las previsiones a largo plazo son constantes.

En la práctica, ϕ rara vez es inferior a 0.8, ya que la amortiguación tiene un efecto muy fuerte para valores más pequeños. Los valores de ϕ cercanos a 1 significarán que un modelo amortiguado no puede distinguirse de un modelo no amortiguado. Por estas razones, solemos restringir ϕ a un mínimo de 0.8 y un máximo de 0.98.

Agregado de estacionalidad



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Triple exponential smoothing - Holt-Winters

Se agrega estacionalidad

$$\hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$$

$$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$$

$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m},$$

Modelos de espacio de estados



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Suavizado exponencial simple con errores aditivos

Recordemos la forma componente del alisado exponencial simple:

$$\begin{array}{ll}\text{Forecast equation} & \hat{y}_{t+1|t} = \ell_t \\ \text{Smoothing equation} & \ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}.\end{array}$$

Si reordenamos la ecuación de suavizado para el nivel, obtenemos la forma de «corrección del error»,

$$\begin{aligned}\ell_t &= \ell_{t-1} + \alpha(y_t - \ell_{t-1}) \\ &= \ell_{t-1} + \alpha e_t,\end{aligned}$$

donde $e_t = y_t - \ell_{t-1} = y_t - \hat{y}_{t|t-1}$ es el residuo en el tiempo t .

Los errores de los datos de entrenamiento conducen al ajuste del nivel estimado a lo largo del proceso de suavizado para $t = 1, \dots, T$. Por ejemplo, si el error en el momento t es negativo, entonces $y_t < \hat{y}_{t|t-1}$ y, por tanto, el nivel en el momento $t - 1$ se ha sobreestimado. El nuevo nivel ℓ_t es entonces el nivel anterior ℓ_{t-1} ajustado a la baja. Cuanto más se acerque α a uno, más «aproximada» será la estimación del nivel (se producen grandes ajustes). Cuanto menor sea α , más «suave» será el nivel (se producen pequeños ajustes).

Suavizado exponencial simple con errores aditivos

Para un modelo con errores aditivos suponemos que los residuos e_t son ruido blanco gaussiano: $e_t = \varepsilon_t \sim \text{NID}(0, \sigma^2)$

Las ecuaciones del modelo de estados quedan:

Ecuación de medida u observación

$$y_t = l_{t-1} + \varepsilon_t$$

Ecuación de estado o de transición de estado

$$l_t = l_{t-1} + \alpha \varepsilon_t$$

- Este modelo se lo denomina ETS(A,N,N)

Error aditivo (A), No considera **Trend** (N) , No considera **Seasonal** (N)

Otros modelos de espacio de estado

ADDITIVE ERROR MODELS

Trend	Seasonal		
	N	A	M
N	$y_t = \ell_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t$	$y_t = \ell_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = \ell_{t-1} s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / \ell_{t-1}$
A	$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$ $b_t = b_{t-1} + \beta \varepsilon_t$	$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$ $b_t = b_{t-1} + \beta \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1}) s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $b_t = b_{t-1} + \beta \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / (\ell_{t-1} + b_{t-1})$
A _d	$y_t = \ell_{t-1} + \phi b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t$ $b_t = \phi b_{t-1} + \beta \varepsilon_t$	$y_t = \ell_{t-1} + \phi b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t$ $b_t = \phi b_{t-1} + \beta \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1}) s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $b_t = \phi b_{t-1} + \beta \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / (\ell_{t-1} + \phi b_{t-1})$

MULTIPLICATIVE ERROR MODELS

Trend	Seasonal		
	N	A	M
N	$y_t = \ell_{t-1} (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} (1 + \alpha \varepsilon_t)$	$y_t = (\ell_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \alpha (\ell_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = \ell_{t-1} s_{t-m} (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} (1 + \alpha \varepsilon_t)$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$
A	$y_t = (\ell_{t-1} + b_{t-1}) (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1}) \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1}) s_{t-m} (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1}) \varepsilon_t$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$
A _d	$y_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1}) \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1}) s_{t-m} (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1}) \varepsilon_t$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$

Ejemplos



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Ejemplos en StatsForecast

Simple exponential smoothing

<https://nixtlaverse.nixtla.io/statsforecast/docs/models/simpleexponentialsMOOTHING.html>

<https://github.com/Nixtla/statsforecast/blob/main/nbs/docs/models/SimpleExponentialSmoothing.ipynb>

Double exponential smoothing - Holt

<https://nixtlaverse.nixtla.io/statsforecast/docs/models/holt.html>

<https://github.com/Nixtla/statsforecast/blob/main/nbs/docs/models/Holt.ipynb>

Triple exponential smoothing - Holt-Winters

<https://nixtlaverse.nixtla.io/statsforecast/docs/models/holtwinters.html>

<https://github.com/Nixtla/statsforecast/blob/main/nbs/docs/models/HoltWinters.ipynb>

AutoETS

<https://nixtlaverse.nixtla.io/statsforecast/docs/models/autoets.html>

<https://github.com/Nixtla/statsforecast/blob/main/nbs/docs/models/AutoETS.ipynb>