

Formación - Series Temporales

Forecasting



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Agenda

- Introduccción.
 - Qué es el forecasting en series temporales?
 - A qué podemos aplicar forecasting?
 - Pasos básicos.
- Presentación de los datos.
- Diferentes modelos de forecasting.
 - Estadísticos: ARIMA y SARIMA.
 - Machine Learning: Árboles, Random Forest, XGBoost.



Introducción



FACULTAD DE
INGENIERÍA





UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Introducción - Qué es el forecasting en series temporales?

- El forecasting en series temporales (ST) es la tarea de predecir **valores futuros** a partir de sus **valores históricos**.
- Las ST tiene diferentes patrones como la **tendencias**, o la **estacionalidad**; que aportan información que nos ayudan a predecir sus valores futuros.
- Existen diferentes métodos para resolver la tarea: **estadísticos, machine learning, o deep learning**.
- También se pueden utilizar variables **exógenas o covariables**.
- **A más grande el valor de h más compleja es la tarea.**

$$f(x_{t-p:t}) = \hat{x}_{t+1:t+h}$$



Introducción - A qué podemos aplicar forecasting?

- El forecasting se requiere en diferentes problemas de toma de decisiones.
 - Si es necesario una nueva planta eléctrica en 5 años.
 - Predecir la demanda eléctrica.
 - Horizonte de años.
 - Ruteo (Telecomunicaciones).
 - Predecir el estado de la red.
 - Horizonte de pocos minutos/segundos.



Introducción - A qué podemos aplicar forecasting?

Lograr buenas predicciones depende de ciertas condiciones:

- Cuán bien se conocen los factores que contribuyen o están relacionados.
- La cantidad de datos disponibles.
- Cuán similar es el futuro respecto al pasado.
- Si las predicciones afectan a aquello que queremos predecir.

Introducción - A qué podemos aplicar forecasting?

Ejemplo: Demanda de energía a corto plazo -> **Predicción posible.**

- Se cumplen las 4 condiciones anteriores:
 - La demanda depende de la temperatura, los días feriados, las condiciones económicas.
 - En general se tienen varios años de datos de demanda, y de la condiciones climáticas.
 - En general se puede asumir que el futuro será similar al pasado.
 - En muchos contextos, la predicción de la demanda no modifica de forma significativa el comportamiento del sistema que se está intentando predecir.

Ejemplo: Tasa de cambio de divisas -> **Predicción poco precisa.**

- **Solo se cumple 1 condición:** Se cuenta con una gran cantidad de datos.
- Por otro lado:
 - Se conocen sólo parcialmente los factores que determinan la evolución del tipo de cambio.
 - Las relaciones entre las variables pueden cambiar con el tiempo.
 - Las predicciones pueden influir en las decisiones de compra y venta de los participantes del mercado.

Introducción - Pasos básicos a tener en cuenta

Paso 1 - Definición del problema:

- Entender para qué se requiere el forecasting.
- Discutir con quién recolecta y mantiene los datos, y con los que utilizarán la herramienta.

Paso 2 - Obtención de datos:

- Datos a aplicar el forecasting. Son suficientes?
- Datos relacionados a factores que contribuyen.

Paso 3 - Exploración de datos:

- Siempre graficar los datos.
- Hay patrones consistentes? Hay una tendencia? Tienen una estacionalidad/periodicidad?
- Existen datos faltantes? Cuántos?
- Existen patrones raros (anomalías) que deban ser explicados por un experto? Cuántos?
- Cuán fuerte es la relación entre las variables en juego?

Introducción - Pasos básicos a tener en cuenta

Paso 4 - Elección y ajuste de modelos:

- El mejor modelo a utilizar depende de varios factores: cantidad de datos, tipo de datos, relación entre variables, entre otros.
- En general se prueba más de un modelo y se los compara.
- Tipo de modelos: regresión, estadísticos, redes neuronales.

Paso 5 - Utilización y evaluación de los modelos:

- El rendimiento solo puede evaluarse adecuadamente una vez que se disponga de los datos del período predicho.
- Al utilizar un modelo en la práctica pueden surgir algunos problemas: como datos faltantes, o datos atípicos, o el tratamiento de series cortas.

Presentación de los datos



FACULTAD DE
INGENIERÍA




UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Datos de demanda

- Estación Mercedes

Período: 14/04/2015 al 12/09/2024 – **Frecuencia:** 1h – **Cantidad de valores:** 82537 – **Media:** 2.415 – **Std.:** 0.642 – **Min.:** -0.007 – **Máx.:** 6.426.




Datos

- Estación Mercedes

- **Entrenamiento:** Período: 14/04/2015 al 31/05/2020 – Cantidad de valores: 80064.
- **Test:** Período: 01/06/2020 al 30/06/2020 – Cantidad de valores: 720.

```
dta_train = dta[:'2020-05-31']  
dta_test = dta['2020-06-01':'2020-06-30']
```



Diferentes formas de forecasting




FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Diferentes formas de predecir

Predicción del instante siguiente




Predicción de una ventana


Instante a instante



Completa



Completa espaciada



Métodos de forecasting: Estadísticos



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

ARIMA

Autoregressive Integrated Moving Average (ARIMA)

Antes de la popularización del *machine learning* y el *deep learning*, el pronóstico de series temporales se realizaba principalmente mediante modelos estadísticos.


- Exponential smoothing: asigna pesos a las observaciones históricas que decaen exponencialmente. Simple, y funciona bien para predicciones locales.

ARIMA (p,d,q):

- Aprovecha la autocorrelación en los datos, y está compuesto de tres componentes principales:
 - AutoRegressive (AR): combinación lineal de los valores pasados. Hiperparámetros **p**.
 - Moving Average (MA): combinación lineal de los errores pasados. Hiperparámetro **q**.
 - Integrated (I): remueve la no-estacionariedad diferenciando los datos. Hiperparámetro **d**.
- Funciona bien para predicciones locales.
- Es una buena opción cuando se cuenta con pocos datos.

Autoregressive Integrated Moving Average (ARIMA)

- Los valores de p , d , y q determinan el modelo.
- Estos pueden ser determinados por expertos a partir de la observación de los datos, y la autocorrelación.



Búsqueda automática:

[pmdarima.arima.AutoARIMA](#)

- Automáticamente busca el orden óptimo de los parámetros.
- Los parámetros elegidos son aquellos que minimicen AIC y BIC.

Predicción del instante siguiente: ARIMA



AutoARIMA para nuestros datos

```
import pmdarima as pm
model = pm.auto_arima(dta_train,
seasonal=False)
```

Hiperparámetros: $p=4$, $d=1$, $q=1$

Predicción del siguiente valor para el conjunto de test

```
history_model = model
predictions = []
for i in range(len(dta_test)):
    forecast = history_model.forecast(steps=1)
    predictions.append(forecast.iloc[0])
    history_model.append(dta_test.iloc[[i]],
refit=False)
```




Predicción del instante siguiente: **ARIMA**

AutoARIMA para nuestros datos

Hiperparámetros: $p=4$, $d=1$, $q=1$


MAE = 0.072
MSE = 0.010
MAPE = 0.028



AutoARIMA para un mes de datos

Hiperparámetros: $p=2$, $d=1$, $q=1$



MAE = 0.072
MSE = 0.009
MAPE = 0.028



Predicción de una ventana (1 semana): ARIMA

Predicción de una semana

```
model.forecast(steps=168)
```



ARIMA modela bien los valores locales, pero no la estacionalidad.

SARIMA

SARIMA

El modelo **SARIMA(p,d,q)(P,D,Q,m)** extiende ARIMA incorporando componentes estacionales:

- Diferenciación estacional (**D**), términos autorregresivos estacionales (**P**) y términos de medias móviles estacionales (**Q**).
- Esto le permite modelar y predecir series temporales que presentan patrones cíclicos o estacionales regulares cada **m** valores.


Predicción del instante siguiente: SARIMA

ARIMA

```
arima_model =  
pm.auto_arima(dta_train,  
              seasonal=False)
```

Hiperparámetros: $p=4$, $d=1$, $q=1$

MAE = 0.072
MSE = 0.010
MAPE = 0.028




SARIMA

```
sarima_model =  
pm.auto_arima(dta_train,  
              seasonal=True,  
              m=24)
```

**Hiperparámetros: $p=3$, $d=1$, $q=1$,
 $P=2$, $D=0$, $Q=1$**



MAE = 0.047
MSE = 0.004
MAPE = 0.019



Predicción de una ventana (1 semana): SARIMA

Predicción de una semana


```
sarima_model.forecast(steps=168)
```



Predicción de una ventana (1 semana): SARIMA

Resultados para todas las semanas del conjunto de test.

MAE = 0.332
MSE = 0.158
MAPE = 0.132



Resultados 1h

MAE = 0.047
MSE = 0.004
MAPE = 0.019

Métodos de forecasting: Machine Learning



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

ÁRBOLES

Árboles

- Los modelos de machine learning pueden aprender **relaciones no lineales** directamente a partir de los datos.
- Funciona con datos tabulares (features).
- Versatil: clasificación o **regresión**. Puede tener salidas múltiples.
- Son el componente fundamental de **Random Forests**, el modelo más poderoso de ML al día de hoy.
- Withe box model: intuitivos y fáciles de interpretar.
- No requiere preparación de los datos.
- Desventajas: tiende a sobreajustarse.





Árboles

Clasificación: ej. flores.

- Clases: **setosa**, **versicolor**, **virginica**.
- # Features = 2: largo (petal length), y ancho (petal width) del pétalo.
- Profundidad máxima = 2.



Entrenamiento: busca la feature y el umbral que devuelva el subconjunto más puro.

Predicciones: Se comienza por el **nodo raíz**, y se avanza respondiendo las preguntas hasta llegar a un **nodo hoja** que determina la clase.



Métodos de forecasting: Árboles

Regresión: ej. Función cuadráticas + ruido.




Métodos de forecasting: Árboles

- Estos métodos suelen clasificarse como **no paramétricos**.
- Sin embargo, es necesario regularizar para evitar el **sobreajuste**.
- **Hiperparámetros (H) de regularización** que limitan la profundidad del árbol:
 - max_depth
 - min_sample_split: mínimo de muestras para dividir una nodo.
 - min_sample_leaf: mínimo de muestras por hoja.
 - max_features: máximo de features evaluadas por nodo.
 - max_leaf_nodes: máximo de hojas.
- Aumentar los min_* o disminuir los max_* regularizarán el modelo.

Métodos de forecasting: Árboles

Regresión: No regularizado vs. Regularizado.





SOBREAJUSTADO!

Árboles

Regresión: Datos de demanda.


- Feature:
 - Hora: [0,1,...,23].
 - Día de la semana: [0,...,6]
 - Día del mes: [0, 30]
- Hiperparámetro:
 - **max_leaf_nodes=5.**




Random Forest

Random Forest

- La combinación de muchos predictores generalmente mejora la performance.




- Bagging:** un mismo algoritmo para cada predictor pero entrenado en un subconjunto de entrenamiento random → **Random Forest**



Random Forest

- Mismos hiperparámetros de regularización que los árboles.
- Nuevo hiperparámetro: cantidad de estimadores (árboles).
- Forecasting de series temporales: **regresión de valores futuros**.
- Features para cada instante de tiempo:



Predicción del instante siguiente: Random Forest

Features:


- Lags: [0, 12].
- Rolling: Ventanas: {24, 168} - mean, std, max, min.
- Marcas: hora, día de la semana, día del mes.

```
rf_1h = RandomForestRegressor(n_estimators=50,  
                              max_leaf_nodes=500)
```

SARIMA

MAE = 0.047
MSE = 0.004
MAPE = 0.019


MAE = 0.056
MSE = 0.006
MAPE = 0.022



Predicción del instante siguiente: Random Forest

Feature importance

- Una cualidad de Random Forest es poder medir la importancia de cada feature.
- La importancia se mide como la suma de los nodos asociados a la feature, cada uno ponderado por la cantidad de muestras entrenamiento. Luego se normaliza por el total.




Predicción de una ventana (1 semana): Random Forest

Features:

- Lags: [0, 12].
- Rolling: Ventanas: {24, 168} - mean, std, max, min.
- Marcas: hora, día de la semana, día del mes.

```
rf_1w = RandomForestRegressor(n_estimators=50,  
max_leaf_nodes=500)
```




SARIMA

MAE = 0.332
MSE = 0.158
MAPE = 0.132



MAE = 0.239
MSE = 0.090
MAPE = 0.090

Predicción RandomForest 1w



Predicción de una ventana (1 semana): Random Forest


Features importance



eXtream Gradient Boosting

Boosting: XGBoost

- Concatenación secuencial de árboles.
- A partir del primer árbol, los siguientes se entrenan para hacer un regresión del residuo.
- El entrenamiento secuencial puede ser muy lento.
- Extreme Gradient Boosting (XGBoost): muy rápido, escalable, y portable.





Predicción del instante siguiente: XGBoost

Features:

- Lags: [0,
- Rolling: V
- Marcas: h


xgb_1h = xgb.2
max_leaf



SARIMA

MAE = 0.047
MSE = 0.004
MAPE = 0.019

MAE = 0.052
MSE = 0.005
MAPE = 0.020




Predicción de una ventana (1 semana): XGBoost

Features:

- Lags: [0, 12].
- Rolling: Ventanas: {24, 168} - mean, std, max, min.
- Marcas: hora, día de la semana, día del mes.

```
xgb_1w = RandomForestRegressor(n_estimators=50,  
                                max_leaf_nodes=500)
```



RF

MAE = 0.239
MSE = 0.090
MAPE = 0.090

MAE = 0.230
MSE = 0.084
MAPE = 0.087

