

Métricas de desempeño para detección de anomalías




FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Performance measurements



-  TP: true positives
success
 -  TN: true negatives
correct rejection
 -  FP: false positives
type I error (false alarm)
 -  FN: false negatives
type II error
-  system login
 disease detection

Total samples: $N = TP + FP + TN + FN$

Accuracy: $ACC = \frac{(TP + TN)}{N}$

Sensitivity/Recall: $TPR = \frac{TP}{(TP + FN)}$

Specificity: $TNR = \frac{TN}{(TN + FP)}$

Precision: $PPV = \frac{TP}{(TP + FP)}$

False positive rate: $FPR = \frac{FP}{(FP + TN)}$

False discovery rate: $FDR = \frac{FP}{(FP + TP)}$

F-score: $F = \frac{2TP}{(2TP + FP + FN)}$

¿cuánto se acerca a los valores reales? exactitud

tasa de enfermos correctamente detectados

tasa de sanos correctamente clasificados

de los clasificados positivos ¿cuántos son los realmente positivos?

probabilidad de una falsa alarma.

Media armónica entre TPR y PPV.

Confusion matrix

		Positive (sick)	Negative (healthy)	
Real labels	Positive (sick)	TP	FN	Positive (sick)
	Negative (healthy)	FP	TN	Negative (healthy)
		Predicted labels		

Confusion matrix

	Positive (sick)	Negative (healthy)
Real labels	TP	FN
	FP	TN
	Predicted labels	

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

- De todas las personas realmente enfermas, cuántas detecta bien mi análisis

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{FP} + \text{TN} + \text{FN})$$

- Aciertos

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$


- De todas las personas que mi análisis indica enfermas, cuántas lo son realmente
- De todas mis detecciones, cuántas son realmente anomalías

F1-score


- Un score que combina precision y recall
- Tener un solo score permite comparar dos clasificadores
- Es la media armónica de precision y recall
 - Da importancia a los valores bajos
 - Un F1 alto se da sólo si precision y recall son ambos altos

$$F_1 = \frac{2}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = \frac{TP}{TP + \frac{FN + FP}{2}}$$


Compromiso precision/recall




Compromiso precision/recall



Curva precision vs recall




Curva ROC - Receiver Operating Characteristic



Curva precision vs recall. Comparación de algoritmos

PR-AUC

Area under curve



Métricas para detección de anomalías en series temporales




FACULTAD DE
INGENIERÍA




UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Anomalías en series temporales

- Tipos de anomalías
 - Puntual: un instante de tiempo
 - Rango: intervalo de tiempo



(a) Precision = 0.6, Recall = 0.5



(b) Precision = ?, Recall = ?

Métricas basadas en rangos para series temporales [1]



Notation	Description
R, R_i	set of real anomaly ranges, the i^{th} real anomaly range
P, P_j	set of predicted anomaly ranges, the j^{th} predicted anomaly range
N, N_r, N_p	number of all points, number of real anomaly ranges, number of predicted anomaly ranges
α	relative weight of existence reward
$\gamma(), \omega(), \delta()$	overlap cardinality function, overlap size function, positional bias function

[1] Tatbul, Nesime, Tae Jun Lee, Stan Zdonik, Mejbah Alam, and Justin Gottschlich. "Precision and Recall for Time Series." In Proceedings of the International Conference on Neural Information Processing Systems (NeurIPS), 1920–30. 2018.
<http://papers.nips.cc/paper/7462-precision-and-recall-for-time-series.pdf>

Range-based recall

Factores que se tienen en cuenta:

- **Existencia:** detectar la existencia de una anomalía (incluso prediciendo sólo un único punto en R_i), por sí mismo, podría ser valioso para la aplicación.
- **Solapamiento**
 - **Tamaño:** cuanto mayor sea el tamaño de la porción de R_i predicha correctamente, mayor será el puntaje de recuperación.
 - **Posición:** en algunos casos, no solo el tamaño, sino también la posición relativa de la porción de R_i predicha correctamente puede ser importante para la aplicación.
 - **Cardinalidad:** detectar R_i con un único rango de predicción $P_j \in P$ puede ser más valioso que hacerlo con múltiples rangos diferentes en P de manera fragmentada.

Range-based recall

$$Recall_T(R, P) = \frac{\sum_{i=1}^{N_r} Recall_T(R_i, P)}{N_r}$$

$$Recall_T(R_i, P) = \alpha \times ExistenceReward(R_i, P) + (1 - \alpha) \times OverlapReward(R_i, P)$$


$$ExistenceReward(R_i, P) = \begin{cases} 1, & \text{if } \sum_{j=1}^{N_p} |R_i \cap P_j| \geq 1 \\ 0, & \text{otherwise} \end{cases}$$

$$OverlapReward(R_i, P) = CardinalityFactor(R_i, P) \times \sum_{j=1}^{N_p} \omega(R_i, R_i \cap P_j, \delta)$$

$$CardinalityFactor(R_i, P) = \begin{cases} 1 & , \text{ if } R_i \text{ overlaps with at most one } P_j \in P \\ \gamma(R_i, P), & \text{ otherwise} \end{cases}$$

Range-based recall

Ejemplos de funciones ω y δ



```
function  $\omega$ (AnomalyRange, OverlapSet,  $\delta$ )  
  MyValue  $\leftarrow$  0  
  MaxValue  $\leftarrow$  0  
  AnomalyLength  $\leftarrow$  length(AnomalyRange)  
  for  $i \leftarrow 1$ , AnomalyLength do  
    Bias  $\leftarrow \delta(i, \text{AnomalyLength})$   
    MaxValue  $\leftarrow$  MaxValue + Bias  
    if AnomalyRange[ $i$ ] in OverlapSet then  
      MyValue  $\leftarrow$  MyValue + Bias  
  return MyValue/MaxValue
```

(a) Overlap size

```
function  $\delta(i, \text{AnomalyLength})$   $\triangleright$  Flat bias  
  return 1  
function  $\delta(i, \text{AnomalyLength})$   $\triangleright$  Front-end bias  
  return AnomalyLength -  $i$  + 1  
function  $\delta(i, \text{AnomalyLength})$   $\triangleright$  Back-end bias  
  return  $i$   
function  $\delta(i, \text{AnomalyLength})$   $\triangleright$  Middle bias  
  if  $i \leq \text{AnomalyLength}/2$  then  
    return  $i$   
  else  
    return AnomalyLength -  $i$  + 1
```

(b) Positional bias

Range-based precision

Factores que se tienen en cuenta:

- **Solapamiento**
 - **Tamaño**
 - **Posición**
 - **Cardinalidad**

Range-based precision

$$Precision_T(R, P) = \frac{\sum_{i=1}^{N_p} Precision_T(R, P_i)}{N_p}$$

$$Precision_T(R, P_i) = CardinalityFactor(P_i, R) \times \sum_{j=1}^{N_r} \omega(P_i, P_i \cap R_j, \delta)$$

Elección de parámetros

- Range-based recall

- α existence-overlap balance $Recall_T(R_i, P) = \alpha \times ExistenceReward(R_i, P) + (1 - \alpha) \times OverlapReward(R_i, P)$
 - $0 \leq \alpha \leq 1$
 - Caso $\alpha=1 \Rightarrow$ Sólo importa la existencia. Con que alguna detección toque R_i alcanza
- $\delta()$ overlap position bias
 - flat, front_end, back_end, middle ([ver diapo](#))
- $\gamma()$ cardinality function
 - por ejemplo $\gamma(x) = 1/x$ $CardinalityFactor(R_i, P) = \begin{cases} 1 & , \text{ if } R_i \text{ overlaps with at most one } P_j \in P \\ \gamma(R_i, P), & \text{ otherwise} \end{cases}$
- $\omega()$
 - definida en general como vimos antes ([ver diapo](#))

- Range based precision

- En general $\alpha = 0$. La mera existencia de una detección no es algo interesante a premiar
- $\delta()$, $\gamma()$ y $\omega()$ podrían definirse distinto al recall
- En general
 - $\alpha = 0$
 - $\delta()$ - flat
 - $\gamma()$ y $\omega()$ similares a recall
-

Métricas de rango son una extensión de las métricas puntuales

- Consideramos anomalías y detecciones por instantes de tiempo
 - Los rangos se fraccionan en rangos unitarios
- Con los parámetros adecuados se obtienen las métricas puntuales
 - $\alpha = 0$
 - $\delta()$ - flat
 - $\gamma(x) = 1$
 - $\omega()$ como vimos antes ([ver diapo](#))



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Métricas que extienden las de rangos (Volume under surface - VUS)

- En [3] discuten los problemas de las métricas puntuales y de rangos
- Proponen considerar el agregado de buffers hacia los lados de las anomalías
- Idea: tener métricas menos susceptibles a cómo se definen los scores de los algoritmos y a cómo se han etiquetado los datasets
- Re-definen las métricas de rango agregando buffers fijos
 - Range-AUC-ROC and Range-AUC-PR
- Definen nuevas métricas agregando buffers variables
 - En lugar de usar el área bajo ROC (TPR, FPR) ,
usar el volumen bajo la superficie ROC(TPR, FPR, L)
 - VUS-ROC y VUS-PR

[3] John Paparrizos, Paul Boniol, Themis Palpanas, Ruey S. Tsay, Aaron Elmore, and Michael J. Franklin. Volume Under the Surface: A New Accuracy Evaluation Measure for Time-Series Anomaly Detection. PVLDB, 15(11): 2774 - 2787, 2022. doi:10.14778/3551793.3551830




Figure 4: Illustration of previous quality measures compared to our proposed measures. By varying the buffer window from 0 to the period, VUS constructs a surface of TPR, FPR, and window. The volume under the surface is a measure of AUC for various windows.



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY